

# Analyse des données publiques sur la qualité de l'eau

Groupe 1A : Noé DEPAEPE, Franklin FLAMENT, Thomas JOSEPHY, Mikael TOM

**Résumé**—Ce projet traite de la qualité de l'eau, un attribut essentiel pour la santé humaine et les écosystèmes. Il vise à développer une application interactive permettant la visualisation de données publiques sous forme de cartes et graphiques à l'aide de *Python* et ses bibliothèques. L'outil permet une analyse comparative entre pays, l'usage d'échelles logarithmiques, une comparaison avec des seuils réglementaires européens et la prévision de tendances via des régressions polynomiales. Ce travail suit la démarche de collecte, filtrage, nettoyage et visualisation, typique du domaine de la *Data Science*.

## I. INTRODUCTION

LA qualité de l'eau est un attribut essentiel à la fois pour les écosystèmes, ainsi que pour la santé humaine. Une eau polluée peut contenir des substances nocives pour la faune et la flore, pouvant entraîner des perturbations écologiques. De ce fait, 1/4 des espèces d'eau douce seraient menacées d'extinction avec comme principale cause la pollution de l'eau [1]. D'autre part, plus de 80% des maladies et 50% des décès infantiles seraient associés à une eau de mauvaise qualité [2].

En parallèle, la préservation de la qualité de l'eau constitue un élément majeur du développement durable puisqu'elle conditionne l'accès à une ressource essentielle pour les générations futures. Son amélioration contribue directement à plusieurs Objectifs de Développement Durable, définis par les *Nations Unies*, en particulier les objectifs relatifs à la santé, à l'eau propre et à la vie aquatique [3].

Dans ce contexte, la mise en place d'un suivi régulier de la qualité de l'eau est nécessaire afin de garantir une gestion adéquate et durable de cette ressource, tant à court qu'à long terme. Ce suivi repose sur l'exploitation de données, qui peuvent être de taille conséquente. La taille de ces données pose des défis en termes de traitement, d'analyse et de visualisation de ces informations.

Le projet présenté dans ce rapport s'inscrit dans cette dynamique. Il vise à développer un programme informatique permettant d'explorer de manière interactive et de centraliser différentes données publiques relatives à la qualité de l'eau, au moyen des cartes interactives, des graphiques et du *Machine Learning*. Il s'inscrit principalement dans le domaine de la *Data Science*, une discipline de l'informatique qui consiste à collecter, filtrer, traiter, analyser et visualiser des données dans le but d'en extraire les plus pertinentes.

Ainsi, le rapport commence par un état de l'art qui présente les autres applications qui permettent de visualiser des données relatives à l'eau, ainsi que leurs limites. Ensuite, la méthodologie suivie est détaillée, en incluant

les hypothèses, les fondements mathématiques, ainsi que le processus utilisé. Enfin, les résultats obtenus à l'aide de cette méthodologie sont illustrés et discutés.

## II. ETAT DE L'ART

En outre, la qualité de l'eau est un sujet central dans des thématiques comme la santé publique et l'environnement. Elle fait l'objet de nombreuses initiatives mises en place par des agences gouvernementales et des organisations internationales, dans le but de collecter, analyser et visualiser différents jeux de données relatifs à la qualité de l'eau.

Parmi ces différents outils figure *Water Quality Portal* [4], une plateforme gouvernementale des États-Unis développée par l'*Environmental Protection Agency*. Bien que l'outil soit complet et contient une quantité conséquente de données temporelles, ce dernier n'offre aucune visualisation.

Une autre plateforme est le portail européen *Water Information System for Europe* (WISE) [5], développé par l'*Agence européenne pour l'environnement* (EEA) qui offre une visualisation des données sur la composition chimique de l'eau des États membres de l'Union européenne. Malgré des jeux de données complets, la visualisation ne se concentre que sur l'Europe et n'intègre aucun modèle prédictif. Il est également peu accessible à une population non éduquée en informatique.

Un autre outil notable est le *Data Portal* de *GEMStat* [6], développé par les *Nations Unies*. Il offre une visualisation des données sur la qualité de l'eau à l'échelle mondiale avec des données pouvant remonter jusqu'à parfois le courant des années 1980. Néanmoins, les performances sont limitées, notamment avec un temps de chargement qui peut être jugé conséquent. De plus, l'outil n'intègre pas de modèles prédictifs.

Pour continuer, la plateforme *Our World in Data* [7], développée par l'Université d'Oxford, propose des graphiques et cartes sur différents indicateurs mondiaux, dont certains liés à la qualité de l'eau et son utilisation. Toutefois, elle ne plus n'intègre pas de modèles prédictifs.

Bien que peu présentes dans ces outils, il faut noter que les techniques d'intelligence artificielle comme le *Machine Learning* commencent à jouer un rôle notable dans l'analyse de la qualité de l'eau. En effet, celles-ci permettent d'intégrer des modèles prédictifs (régression linéaire, régression à angles minimaux, régression bayésienne) qui peuvent anticiper des tendances avec un taux de précision élevé [8].

Par conséquent, la majorité de ces solutions reste difficilement accessible au grand public, se restreint à des zones géographiques précises, sans nécessairement proposer une

perspective globale, ou ne centralise pas différents jeux de données décrivant différentes mesures. Les données présentées sont également peu expliquées et mises en contexte.

En ce sens, le projet présenté dans ce rapport vise à combler ces manquements en proposant un programme informatique interactif, à la fois scientifique mais aussi pédagogique et facile d'utilisation pour les utilisateurs. En gardant toujours à l'esprit que ce projet serait présenté au Printemps des Sciences 2025, nous avons choisi d'exploiter et de raffiner au mieux le côté pédagogique et facile d'utilisation de notre projet. *Aquastat* combine visualisations de données à l'échelle locale et mondiale, tout en centralisant différents jeux de données concernant la composition de l'eau mais aussi des mesures liées à l'Objectif de Développement Durable 6 : *eau propre et assainissement*. Pour ce faire, des cartes, des graphiques interactifs, des systèmes de classement et de comparaison avec les seuils réglementaires européens, établis lors des différentes *Water Framework Directives*, sont utilisés. Par ailleurs, un aspect temporel est intégré avec des prédictions possibles.

### III. MÉTHODOLOGIE

#### A. Les hypothèses de base

Nous nous sommes basés sur différentes hypothèses lors de l'élaboration de ce projet. La première hypothèse étant que les données utilisées sont suffisamment représentatives de la qualité de l'eau à l'échelle planétaire, et qu'elles aient été vérifiées par des scientifiques spécialisés dans le domaine en amont. Nous avons également supposé que les données historiques suivent une tendance continue et que cette dernière restera approximativement similaire dans un futur proche.

#### B. Choix des composés chimiques présentés

Face à un grand nombre de composés chimiques analysés et disponibles, nous avons dû nous restreindre à une certaine sélection afin d'améliorer la clarté et la pertinence des données visualisables. Nous reconnaissons cependant que, n'ayant pas d'éducation académique approfondie en chimie, nous avons pu commettre des erreurs quant à l'explication de certains composants, ou peut-être que certains composants non sélectionnés auraient pu être plus pertinents que ceux que nous avons choisis. Il est notable que d'autres composants qui peuvent être nocifs n'ont pas été mentionnés sur aucune des cartes ou graphiques, et cela peut être dû à un choix de clarté, ou encore un manque crucial de données. En effet, plusieurs de ces informations peuvent ne pas être collectées dans toutes les régions du monde, ce qui peut introduire une certaine inexactitude dans l'analyse et des "trous" de données, rendant l'analyse et la visualisation peu pertinente.

#### C. Les fondements mathématiques

Puisque le but est de traiter des jeux de données, peu d'algorithmes et de formules mathématiques ont

été employés. Néanmoins, des formules se sont avérées utiles. Par exemple, pour comparer la qualité de l'eau de différentes régions, la moyenne empirique est utilisée.

Formule de la moyenne empirique :

$$\bar{x} = \frac{(x_1 + x_2 + \dots + x_n)}{n} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

La moyenne empirique s'inscrit dans le cadre de ce projet comme une mesure importante, propre à chaque pays dans le but de centraliser les données relevées dans différents points d'eau vis-à-vis de chacun des composants chimiques séparément, afin d'en faire une moyenne et de pouvoir comparer différents pays entre eux sur un même sujet en particulier (comme la concentration en nitrate par exemple).

Ensuite, afin de permettre une visualisation plus claire et détaillée, l'échelle logarithmique est utilisée.

Formule pour transformation en échelle logarithmique :

$$y = \log(1 + x) \quad (2)$$

où :

- $y$  est la valeur transformée sur l'échelle logarithmique,
- $x$  est la valeur d'entrée.

Elle est employée afin de diminuer les écarts parfois drastiques de données sur une même unité entre différents pays. En appliquant cette transformation, les grandes différences entre les valeurs sont réduites, facilitant ainsi l'analyse et la comparaison des données, notamment lorsqu'elles sont fort disparates.

Pour continuer, une régression polynomiale est utilisée pour prédire les futures valeurs concernant la qualité de l'eau.

La formule générale de la régression polynomiale :

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_n x^n \quad (3)$$

où :

- $y$  représente la qualité de l'eau que l'on cherche à prédire (variable dépendante),
- $x$  correspond à l'année (variable indépendante) utilisée pour effectuer la prédiction.

Pour évaluer les résultats, l'Erreur Quadratique Moyenne (RMSE) est utilisée

Formule de l'Erreur Quadratique Moyenne :

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (4)$$

- $y_i$  : Valeurs réelles, les valeurs observées ou mesurées pour chaque échantillon  $i$ .

- $\hat{y}_i$  : Valeurs prédites, les valeurs estimées par le modèle pour chaque échantillon  $i$ .
- $n$  : Nombre de points de données, le nombre total d'échantillons dans l'ensemble de données.

#### D. La méthode proposée

Afin de rendre ces données lisibles, qui au premier abord sont peu accessibles pour des personnes n'ayant pas de connaissances poussées dans le domaine de l'informatique, nous avons employé un panel de méthodes cumulées afin de rendre tout cela visuel et interactif. Pour commencer notre méthodologie, nous avons récolté les données sur différents sites et bases de données. Les jeux de données utilisés proviennent de :

- GEMStat [9]
- European Environment Agency (EEA) [10]
- AQUASTAT [11]

Nous rencontrons ici un premier problème : toutes les bases de données ne sont pas disponibles sous les mêmes formats : *EEA* propose une base de données en SQL, tandis que *Gemstat* et *Aquastat* proposent de télécharger les données en format CSV. Le premier objectif était de nettoyer et filtrer ces dernières afin de ne préserver qu'une partie des données présentes. Les valeurs extrêmes, les doublons et les valeurs nulles ont été supprimés afin de ne garder que les données les plus pertinentes. Dans le cadre de *EEA* des requêtes *SQLite3* sont utilisées pour extraire les informations nécessaires depuis les différentes bases de données. Au sein même de celles-ci, le filtrage des valeurs nulles est fait.

```
SELECT Information
FROM DataBase_Table
WHERE Information_A IS NOT NULL;
```

Listing 1 – Exemple de requête SQL qui ne récupère pas les lignes avec des valeurs nulles

Concernant les doublons, ils ont été supprimés à l'aide d'une méthode de la librairie *Pandas*. Les données à valeurs négatives ou excessivement élevées ont également été supprimées. Pour ce faire, les valeurs en dessous d'un seuil minimum de 0 ont été retirées tout comme les valeurs qui dépassaient 100 fois la moyenne calculée (sans les valeurs négatives).

Pour les fichiers en CSV, nous les transformons d'abord en *Data Frame* *Pandas*. De manière similaire aux bases de données, les valeurs nulles et les doublons ont été retirés. Pour ce faire, des méthodes de la librairie *Pandas* ont été utilisées. Les valeurs erronées ont été converties en valeurs nulles puis supprimées.

Un travail d'harmonisation a eu lieu au préalable de la transformation en format *.json* afin de notamment passer pour le "country code" de chaque pays de la norme ISO2 à la norme ISO3.

En outre, il faut noter que toutes les données nettoyées n'ont pas été utilisées, seules celles jugées les plus pertinentes (métaux lourds, ...) et disposant d'un volume d'informations suffisant ont été conservées.

Pour continuer, la moyenne empirique est ensuite calculée pour chacun des paramètres sélectionnés. Le calcul est possible grâce à une méthode de la librairie *Pandas* pour les données venant d'un fichier *.csv*, tandis que pour celles venant des bases de données *.sqlite3*, cela se fait directement à l'aide de requêtes.

Suite à ce travail apporté sur l'ensemble des données, notre choix a été de placer ces données extraites et les moyennes calculées dans un ensemble de fichiers *.json*. D'une part, l'objectif est d'éviter de demander constamment aux bases de données, étant volumineuses, des informations redondantes et de risquer de ralentir le programme. L'idée est donc de sauver les résultats de ces requêtes, puisqu'elles seront systématiquement identiques. D'une autre part, l'avantage d'une telle approche est que ces types de fichiers sont à la fois portables et légers, tout en étant faciles à intégrer à des programmes *Python*. Pour effectuer ces enregistrements dans des fichiers *.json*, les résultats extraits sont stockés dans des tableaux (*Data Frame*) de la librairie *Pandas* qui sont ensuite convertis en fichier *.json* à l'aide d'une méthode de cet outil.

Ensuite, une approche de *Machine Learning* pour prédire les futures valeurs concernant l'utilisation de l'eau est employée. Elle se base sur la régression polynomiale. Pour ce faire, les données disponibles sont extraites depuis l'un des fichiers *.json*, créé lors de l'étape précédente. Un bruit aléatoire compris entre 0.01 et 0.05 est ajouté afin de simuler des variations naturelles ou des erreurs de mesures de données. Ces valeurs ont été choisies car elles sont suffisamment faibles pour ne pas altérer considérablement les tendances. Ensuite, un modèle de régression polynomiale est entraîné et testé avec différents degrés de polynôme, allant de 1 à 3. Cela est possible grâce à la librairie *Scikit-learn*, qui offre des outils efficaces pour la construction et la validation de tels modèles.

Pour l'entraînement et la validation du modèle, la méthode *TimeSerieSplit* est utilisée. Cette approche permet de diviser les données en différents sous-ensembles chronologiques. Le modèle est entraîné pour ces différents sous-ensembles avec un degré de polynôme spécifique. Les prédictions obtenues sont comparées entre elles en calculant le RMSE. Le degré de polynôme qui minimise cette valeur est retenu. Avec les meilleurs modèles trouvés, les futures valeurs sont prédites. Toutes ces prédictions sont stockées dans un fichier *.json*.

Concernant la visualisation des données, un site internet a été choisi comme support, puisque l'un des objectifs était de rendre les données accessibles au grand public, sans nécessiter de compétences techniques ou d'installations particulières. Afin de mettre en place ce site, le langage interprété *Python* a été utilisé pour créer chacune des pages avec différents composants à l'aide de la librairie *Dash*. Au sein de celles-ci, différentes cartes et graphiques sont intégrés. Ces figures sont construites à l'aide de la librairie *Plotly*, qui permet de créer des visualisations réactives aux actions des utilisateurs.

Ce processus de création suit plusieurs étapes. Tout d'abord, les données nécessaires sont extraites du fichier

.json correspondant tout en étant placées dans des *Data Frames*. Ensuite, les données sont filtrées selon les indicateurs choisis par l'utilisateur. Les codes ISO3 des pays sont convertis en leur nom complet à l'aide de *Pycountry*. Les données sont converties à l'échelle logarithmique, si l'option est sélectionnée par l'utilisateur. Enfin, le processus de création de figures associe chaque pays à une valeur qu'il récupère à l'aide du *Data Frame*. En outre, une coloration de la carte ou du graphique est effectuée. Il faut noter que ce processus peut varier et inclure d'autres étapes en fonction du type de figures sélectionné. Par exemple, une étape de comparaison avec les seuils législatifs peut être appliquée. Ceux-ci sont définis à partir des *Water Framework Directives* de l'Union Européenne pour des éléments comme : l'Ammonium [12], le BOD5 [13], le Cadmium [14] ainsi que le Nickel, le Plomb et le Mercure [15].

Ainsi, l'ultime étape de ce processus était de rendre le tout agréable à l'œil du public, et pour ce faire, nous avons utilisé le langage *CSS* permettant d'embellir le tout. De manière similaire, l'API *Mapbox* a été utilisée afin de générer des cartes personnalisées visuellement plus attrayantes. Pour ce faire, un "token" est généré depuis la plateforme.

TABLE I – Bibliothèques Python et leurs fonctions

| Librairie | Fonction                                             |
|-----------|------------------------------------------------------|
| Dash      | Création du site web avec les cartes et graphiques   |
| Plotly    | Création cartes et graphiques interactifs            |
| Numpy     | Mise en échelle logarithmique, calcul de moyenne,... |
| Sqlite3   | Interagir avec des bases de données SQLite           |
| Sklearn   | Machine Learning : construction de modèles           |
| Pandas    | Manipulation et analyse de données                   |
| Pycountry | Conversion ISO2 vers ISO3 vers le nom complet        |





FIGURE 1 – Schéma général de type workflow décrivant l'architecture et la méthodologie du projet


## IV. RÉSULTATS

En appliquant la méthodologie décrite dans la section III, nous sommes parvenus à différents résultats présentés dans cette section.

### A. Échelle logarithmique



(a) Sans échelle logarithmique



(b) Avec échelle logarithmique

FIGURE 2 – Carte de la concentration moyenne en Ammonium par pays Européen (mg/L), avec et sans échelle logarithmique. Ces données proviennent de l'*European Environment Agency (EEA)*.

La Figure 2 met en évidence l'impact au niveau de la visualisation des données sur la carte lorsque l'échelle logarithmique est présente ou non. Au sein de la Figure 2a, sans échelle logarithmique, la carte indique une répartition des couleurs en fonction des concentrations linéaires. C'est-à-dire que les pays avec des concentrations élevées dominent visuellement avec une coloration très marquée, par exemple, le Monténégro (moyenne : 14.1 mg/L) qui est en jaune. Tandis que les pays à faibles valeurs, comme la France (moyenne : 0.42 mg/L), apparaissent avec des couleurs similaires. En effet, le panel de couleur permet de représenter qu'un écart constant entre chaque valeur, un pays avec des valeurs extrêmes fait augmenter le panel, et impacte le rendu final car les pays aux valeurs proches se voient réduits à une petite partie de l'échelle seulement.

En revanche, la carte de la Figure 2b, avec l'échelle logarithmique, montre une coloration plus variée entre les différents pays à faibles concentrations. L'échelle logarithmique a pour effet de comprimer les valeurs les plus élevées tout en étendant les plus faibles. Cela permet de distinguer plus facilement les pays à faibles concentrations entre eux.

### B. Utilisation de .json

Le tableau ci-dessus démontre l'importance de l'utilisation des fichiers au format .json dans notre projet. En effet,

TABLE II – Comparaison : SQLite vs JSON

| Numéro de Test | Durée SQLite (s) | Durée JSON (s) |
|----------------|------------------|----------------|
| 1              | 21.69            | 0.1896         |
| 2              | 20.53            | 0.1889         |
| 3              | 19.60            | 0.1901         |
| 4              | 19.59            | 0.2025         |
| 5              | 20.65            | 0.2082         |
| 6              | 20.77            | 0.2013         |
| 7              | 20.14            | 0.1931         |
| 8              | 20.69            | 0.2094         |
| 9              | 19.85            | 0.1641         |
| 10             | 19.68            | 0.1636         |
| <b>Moyenne</b> | <b>20.32</b>     | <b>0.1911</b>  |


Tableau comparatif des durées (secondes) de création de carte en récupérant les données depuis un JSON ou depuis une Bases de données SQLite lors de 10 tentatives, avec la moyenne est indiquée en dessous. Pour reproduire cette expérience, il suffit de suivre l'implémentation fournie (voir Annexe A).

pour une base de données d'approximativement 20 Go, ce format réduit à près de 700 Ko uniquement par carte. En effet, il ne conserve que les résultats et se contente de les afficher, tandis que SQLite nécessite une requête à la base de données elle-même, devant ainsi traverser l'ensemble des données avant de pouvoir afficher les résultats. Le côté négatif de ce format est la nécessité de charger le résultat des requêtes dans le *.json* en lançant le programme, ce qui, au démarrage, le ralentit, mais cela ne sera impactant qu'à cet unique moment. Cependant, ce temps de chargement n'est pas toujours nécessaire puisque les fichiers *.json* sont peu volumineux et simples à partager, ce qui les rend faciles à télécharger. Ainsi, l'utilisation de fichiers *.json* est préférable dans notre contexte pour la fluidité du programme.


### C. Prédictions

Les Figures 3a et 3b représentent les données prédites pour différents paramètres. La première indique une légère baisse pour les valeurs futures tandis que la seconde montre une augmentation. Chaque graphique présente 3 courbes (orange, vert, bleu clair) allant des années 2000 à 2030. Il s'agit des différents modèles polynomiaux de degrés 1 à 3. Ces courbes sont des fonctions mathématiques qui approximent les points des années 2000 à 2022. Chacune possède une RMSE associée qui mesure leur précision. Comme indiqué dans la section III, la courbe ayant l'erreur quadratique moyenne la plus basse est retenue pour prédire les futures valeurs. Par exemple, dans la Figure 3b, le modèle choisi de degré 2 possède une RMSE de 0.63 tandis que les deux autres ont des valeurs de 0.67 et 0.77.

Par conséquent, ces graphiques montrent que le choix du degré de polynôme est essentiel pour prédire des valeurs cohérentes et probables. Par exemple, la Figure 3a met en évidence que la courbe de degré 1 ne capture pas avec précision les fluctuations des valeurs de 2000 à 2022. Cela indique que si les données prédites suivaient ce modèle, elles seraient peu plausibles puisque cela évolue



(a) Prédictions pour l'Indonésie appliquées à l'utilisation de l'eau pour l'agriculture en % des ressources renouvelables totales.



(b) Prédictions pour le Nigéria appliquées sur le stress hydrique (ODD 6.4.2)

FIGURE 3 – Graphiques montrant les données prédites à l'aide de la Régression Polynomiale pour l'Indonésie et le Nigeria. Les points bleus indiquent les valeurs de 2000-2022 et les croix rouges montrent les données prédites de 2023 à 2030. Les courbes sont les modèles polynomiaux (1 à 3) avec leur RMSE. Ces données proviennent d'AQUASTAT.

de manière linéaire et trop croissante. En effet, de 2012 à 2022, l'indice a augmenté approximativement de 1%, tandis qu'il croît de plus d'environ 2% de 2023 à 2030, soit en 8 ans. Une croissance aussi brusque peut sembler très peu réaliste. De manière similaire, la courbe degré 3 diminue de manière brusque. Ce comportement illustre un phénomène d'*overfitting*. C'est-à-dire que le modèle de degré 3 s'ajuste trop précisément aux points de données et ses variations. La conséquence est que la courbe est très précise pour les valeurs réelles de 2000 à 2022 tandis que pour celles de 2023 à 2030, le modèle devient instable. En revanche, la courbe retenue de degré 2 possède une décroissance modérée. De plus, elle semble stable tout comme les années 2014 à 2022, ce qui indique qu'elle suit de manière cohérente les anciennes données tout en proposant des prédictions plausibles.

Ainsi, utiliser une régression polynomiale afin de prédire de futures valeurs peut être cohérent et efficace, cependant il faut faire attention à l'*overfitting* ou l'*underfitting*.

## V. UTILISATION D'OUTILS D'IA GÉNÉRATIVE

L'outil *ChatGPT* a été utilisé comme "copilote" dans ce projet, notamment pour embellir le travail déjà réalisé. Il a



été utile pour optimiser le code Python en le rendant plus clair, plus concis, en changeant des noms de variables et de fonctions. Il a également été utile pour le débogage. Des exemples de prompts sont : "Voilà notre code, explique pourquoi l'erreur suivante apparaît." ou alors "Voici un code Python, donne-nous des idées ou des bibliothèques qui rendraient cela plus concis.". L'outil a aussi été employé pour corriger la syntaxe et l'orthographe dans le rapport afin d'améliorer la fluidité et la structure de notre texte. Pour ce faire, nous lui donnions un extrait du rapport et nous lui demandions de l'améliorer jusqu'à ce que le résultat nous convienne. Un exemple de prompt est : "Voici un paragraphe de notre rapport, dis-nous ce qui pourrait être amélioré.". Il est important de noter que toutes les propositions ont été revues et modifiées en gardant un esprit critique. L'objectif d'un tel outil était de critiquer notre travail afin de le remettre en question.

## VI. CONCLUSION

En conclusion, ce projet a permis de concevoir un programme informatique permettant d'explorer diverses données publiques relatives à la qualité de l'eau. Contrairement à d'autres approches, notre solution centralise plusieurs jeux de données publiques, propose des visualisations claires pour tout type de public, présente des données à l'échelle mondiale et intègre des prédictions à l'aide d'un modèle de régression polynomiale.

L'utilisation de diverses bases de données lors du projet nous a permis d'apprendre et d'explorer quelques principes essentiels de la *Data Science* : traitement des données, sélection, agrégation,... Entre autres, il a été observé que l'utilisation de régressions polynomiales avec sélection du meilleur degré de polynôme via le RMSE permet d'obtenir des prédictions cohérentes et exploitables. Cependant, il faut toujours veiller à ne pas faire de l'*overfitting* ou de l'*underfitting*.

Pour les perspectives futures, l'application pourrait être enrichie par d'autres techniques de *Machine Learning* plus avancées comme des réseaux de neurones. De manière similaire, un système communautaire qui met à jour régulièrement les cartes ou en ajoute d'autres pourrait permettre une maintenance pertinente du site tout en évoquant divers autres aspects liés à d'autres facteurs. Toutefois, cela reste impossible sans des bases de données riches, variées et exactes. *Aquadata* pourrait donc croître et s'améliorer au fur et à mesure que des analyses sur la qualité de l'eau soient menées et publiées par les institutions compétentes.

## RÉFÉRENCES

- [1] C. A. Sayer, E. Fernando, R. R. Jimenez, et al. One-quarter of freshwater fauna threatened with extinction. *Nature*, 638 :138–145, 2025.
- [2] Li Lin, Haoran Yang, and Xiaocang Xu. Effects of water pollution on human health and disease heterogeneity : A review. *Frontiers in Environmental Science*, Volume 10 - 2022, 2022.
- [3] Joseph Alcamo. Water quality and its interlinkages with the sustainable development goals. *Current Opinion in Environmental Sustainability*, 36 :126–140, 2019. Environmental Change Assessment.

- [4] United States Environmental Protection Agency (EPA). Water quality portal (wqp). <https://www.waterqualitydata.us/>, 2025. Consulté le 25 avril 2025.
- [5] European Environment Agency (EEA). Wise – water information system for europe. <https://www.eea.europa.eu/themes/water>, 2025. Consulté le 25 avril 2025.
- [6] United Nations Environment Programme (UNEP). Gemstat data portal – global water quality data and statistics. <https://gemstat.org/>, 2025. Consulté le 25 avril 2025.
- [7] Our World in Data – University of Oxford. Our world in data : Global water quality and environmental indicators. <https://ourworldindata.org/>, 2025. Consulté le 25 avril 2025.
- [8] Raed Jafar, Adel Awad, Iyad Hatem, Kamel Jafar, Edmond Awad, and Isam Shahrouh. Multiple linear regression and machine learning for predicting the drinking water quality index in al-seine lake. *Smart Cities*, 6(5) :2807–2827, 2023.
- [9] GEMStat. Global environmental monitoring system for freshwater quality (gemstat). <https://www.gemstat.org>, 2025. Consulté le 25 avril 2025.
- [10] European Environment Agency (EEA). Water quality – european environment information and observation network (eionet). <https://www.eea.europa.eu/themes/water>, 2025. Consulté le 25 avril 2025.
- [11] Food and Agriculture Organization of the United Nations (FAO). Aquastat – fao's global information system on water and agriculture. <http://www.fao.org/aquastat>, 2025. Consulté le 25 avril 2025.
- [12] T. Di Lorenzo, M. Cifoni, P. Lombardo, et al. Ammonium threshold values for groundwater quality in the eu may not protect groundwater fauna : evidence from an alluvial aquifer in italy. *Hydrobiologia*, 743 :139–150, 2015.
- [13] M. Lewoyehu, D. Fentahun, and S. Addisu. Evaluation of koga irrigation water in mecha district, amhara region, as an example of irrigation water quality in northwestern ethiopia. *Applied Water Science*, 13 :196, 2023.
- [14] Mark Crane and Marc Babut. Environmental quality standards for water framework directive priority substances : Challenges and opportunities. *Integrated Environmental Assessment and Management*, 3(2) :290–296, 2007.
- [15] UK Government. The water framework directive (standards and classification) directions (england and wales), 2015. UK Statutory Instrument 2015/1623.

## ANNEXE A

### CODE DE LA COMPARAISON SQLITE VS JSON

```
def charger_donnees_sqlite: # Charger .sqlite3
    executer_requete_SQL
    transformer_resultat_en_dataframe
    return dataframe

def charger_donnees_json: # Charger .json
    lire_fichier_json
    transformer_json_en_dataframe
    return dataframe

def creer_carte_dataframe: # Creation de carte
    creation_de_carte_plotly

def comparer_performances: Comparaison des performances
    for i in range(10):
        demarrer_chronometre
        donnees_sqlite = charger_donnees_sqlite
        creer_carte donnees_sqlite
        enregistrer_temps_sqlite
        demarrer_chronometre
        donnees_json = charger_donnees_json
        creer_carte donnees_json
        enregistrer_temps_json
        calculer_moyennes
        sauvegarder_resultats_csv
```

Listing 2 – Pseudocode JSON vs SQLite réalisée sur Waterbasev2022WISE6DisaggregatedData.sqlite de EEA.